

A Spatio-Spectral Fusion Method for Hyperspectral Images Using Residual Hyper-Dense Network

Jiahui Qu , Member , IEEE, Zhangchun Xu, Wenqian Dong , Member , IEEE, Song Xiao, Y unsong Li ,
Member , IEEE, and Qian Du , Fellow, IEEE

摘要

全色 (PAN) 和高光谱 (HS) 图像的空间-光谱融合对于提高许多商业 HS 传感器获得的图像的空间分辨率具有重要意义。密集网最近在图像超分辨率方面取得了巨大的成功,因为它们通过以前馈方式串联所有的特征输出来促进梯度流动。在这篇文章中,我们提出了一个剩余超密集网络 (RHDN),它扩展了密集网以解决空间-光谱融合问题。所提出的 RHDN 方法的整体结构是一个双分支网络,这使得该网络能够分别捕捉可见范围内和可见范围外的 HS 图像的特征。在网络的每个分支,设计了一个双流特征提取策略来单独处理 PAN 和 HS 图像。一个带有级联残余超密块 (RHDBs) 的卷积神经网络 (CNN),允许同一流内的层对和不同流的层对之间的直接连接,被提出用于学习 HS 和 PAN 图像之间更复杂的组合。残差学习被采用来使网络高效。广泛的基准评估表明,所提出的 RHDN 融合方法比许多广泛接受的最先进的方法有明显的改进。

关键词: DenseNet; 高光谱 (HS) 泛锐化; 残余超密集网络 (RHDN); 空间-光谱融合。

1 引言

具有数百个窄光谱带的高光谱 (HS) 图像具有区分物质的潜力,并已被广泛用于许多遥感任务,如土地覆盖分类^[1-2],变化检测^[3]和场景解释^[4]。然而,由于物理上的限制,用一个传感器直接获取光谱和空间领域的高分辨率的 HS 图像是无法实现的。全色 (PAN) 和多光谱 (MS) 图像 (与 HS 图像在同一区域同时获取) 的空间分辨率可以相对高于 HS 图像的空间分辨率。越来越多的学者研究了 PAN 和 HS 图像的空间-光谱融合或 MS 和 HS 图像的空间-光谱融合^[5-7]。本文旨在研究 PAN 和 HS 图像的空间光谱融合。PAN 和 HS 图像的空间-光谱融合,也被称为 HS 泛锐化,构成了通过结合低分辨率 (LR) HS 图像的光谱内容和 HR-PAN 图像的空间细节来创建高分辨率 (HR) HS 图像的唯一可能性。

2 相关工作

此部分对传统的泛锐化方法、目前先进的基于 CNN 的泛锐化方法进行介绍以及分析存在的问题,针对问题提出动机。

2.1 传统泛锐化方法

近年来,社会各界对 HS 泛锐化表现出了极大的兴趣。已经有很多算法被提出来用于 HS 分辨率增强,有两种观点被更广泛地用于分组这些方法^{[8],[9]}。在^[8]中,根据是否使用点扩散函数 (PSF),将 HS 分辨率增强方法归为四类。第一类需要使用 PSF,第二类是不基于 PSF 的,需要 HR-PAN 图像。第三类和第四类是单图像超分辨率方法。第三类和第四类的关键区别在于,第四类需要一些训练图像和步骤,不需要关于 PSF 的知识。Kwan 等人^[8]通过论证获得了一些有价值的信息,即仅靠单图超分辨率不足以产生良好的 HR-HS 图像,在融合过程中加入 PSF 可能有助于提高融合性能。

在^[9]中, 泛锐化方法大致分为四大类: 分量替换 (CS)、多分辨率分析 (MRA)、贝叶斯法和矩阵分解法。CS 方法依赖于将 HS 图像转换到一个新的域来分离空间和光谱信息。随后, 包含空间信息的分离后的空间分量被 PAN 图像完全或部分替代, 最后通过反投影得到泛锐化的 HS 图像。CS 类方法非常简单且效率很高。然而, 它们的性能在光谱失真方面是有限的, 这是由 PAN 图像和它的替代成分之间的不匹配引起的。与基于 CS 的方法相比, MRA 系列通常具有更高的光谱保真度, 因为它们可以很好地保留 HS 图像的原始光谱内容。MRA 方法通常将从 PAN 图像中提取的空间细节分解成多个通道, 然后将空间信息注入插值 HS 图像的相应通道中。然而, 它们在空间增强方面通常不能令人满意。这是因为对于许多卫星来说, HS 和 PAN 传感器捕获的空间细节是相当不同的。贝叶斯法和矩阵分解法可以归结为“基于模型的方法”, 他们将 HS 图像和 PAN 图像分别建模为理想的 HR HS 图像的退化版本和线性组合。理想的 HR-HS 图像是通过估计不理想的问题的解来恢复的。贝叶斯融合技术在很大程度上依赖于 HS 波段和 PAN 图像之间的统计关系。矩阵分解^[10]的基本思想是将原始矩阵分解为两个矩阵的乘积, 从而减少原始高维矩阵。基于模型的方法在保持光谱信息和增强空间细节方面显示出相当大的潜力。然而, 要想获得不理想的逆问题的良好解决方案是很困难的, 也很耗时。

2.2 基于 CNN 的泛锐化方法

卷积神经网络 (CNN) 已经成功地应用于许多遥感任务的图像增强, 特别是图像超分辨率, CNN 不仅在 MS 泛锐化方面取得了巨大成功, 而且在 HS 泛锐化方面也取得了巨大成功。Zheng 等人^[11]提出了一个由深度 HS 先验 (DHP) 和双注意残差网络 (DARN) 组成的框架。然而, 这些现有的基于 CNN 的 HS 泛锐化方法采用前端融合或后端融合策略, 在网络的输入或输出端整合 PAN 图像的特征和 HS 图像的特征, 未能充分地利用所有卷积层的信息。例如, 在^[11]和^[12]中, 从 PAN 和 HS 图像中提取的特征在网络的输入端沿着光谱维度被连接起来。然而, PAN 图像表现出高空间分辨率, 但光谱内容有限。HS 图像的特点是光谱信息丰富, 但空间分辨率较低。因此, PAN 图像和 HS 图像显示出明显不同的统计特性。要探索这两种图像的低层次特征之间的非线性映射是很困难的。到目前为止, 跨多个数据流的超密集连接的影响及其在 HS 泛锐化中的应用仍未被探索。

此外, 大多数现有的基于 CNN 的 HS 泛锐化方法最初是为 MS 图像的泛锐化设计的。正如人们所期望的, HS 图像的泛锐化要比 MS 图像的泛锐化复杂得多。这是因为 HS 图像的光谱采集范围比 PAN 图像要宽得多。PAN 图像只覆盖可见光光谱范围, 但 HS 图像通常覆盖可见光到短波红外 (SWIR) 光谱范围。因此, 当 PAN 和 HS 图像的光谱范围不一致时, HS 和 PAN 图像的融合比 MS 和 PAN 图像的融合更具挑战性。泛锐化模型很难在 PAN 图像未覆盖的光谱范围内估计 LR-HS 图像的缺失细节^[9]。

为了应对上述挑战, 我们的动机从两个方面进行了详细描述。首先, 可见光光谱外部的空间信息缺失比可见光光谱的空间信息缺失更难估计。应分别增强可见光谱内部和外部的空间信息估计。然而, 现有的高光谱泛锐化研究在可见光谱内和外都进行了统一的处理。其次, 现有的基于 CNN 的算法主要集中在低层次特征融合或高层次特征融合上, 目前还没有将低层次特征融合和高层次特征融合有效结合起来, 充分挖掘高光谱图像和全色图像的特征。

基于上述动机, 提出了一种新型的空间-光谱融合框架, 即残余超密集网络 (RHDN)。主要贡献简要地概括如下。1) 我们提出了一种新型的 RHDN, 它可以估计可见光谱内外缺失的空间细节, 并通过合并 HS 和 PAN 图像的低级特征和高级特征来充分挖掘特征。提出的 RHDN 优于其他最先进的

网络。2) 探索了一种新的剩余超密集块 (RHDB)。RHDB 在 HS 和 PAN 特征提取流内部和中间的不同层之间建立了密集的连接, 显示了强大的特征表示。据我们所知, 这是第一个在不同流的所有层内和层间直接连接的工作, 以融合 HS 和 PAN 图像的分层特征, 解决 HS 空间光谱融合的问题。3) 在提出的 RHDN 方法中, 我们设计了两个特征提取分支, 分别捕捉可见光谱范围内和可见光谱范围外的 HS 图像的特征, 以便于估计可见光谱内外缺失的空间细节。

2.3 密集残差模块 RDB 及其衍生模块

^[13]的研究开发了一个新颖的密集残差网络 (RDN), 以充分利用所有卷积层的层次特征。RDN 是建立在从密集残差块 (RDB) 的卷积层到所有后续层的直接访问以及从一个 RDB 到下一个 RDB 的每一层的直接连接的想法上。RDB 设计了密集连接的卷积层来提取丰富的局部特征 [图 1(a)]。RDN 结构特别适合解决超分辨率问题, 原因如下。1) 它通过充分使用局部和全局特征实现了深度监督; 2) 所有层之间的密集连接有助于解决梯度消失问题。受 RDB 在超分辨率任务中的成功启发, 许多特征提取块被提出。为了提高网络收敛速度, 提出了一个带有深层 RDB 的深层残余致密网络 (DRDN) [图 1(d)], 它从浅层特征引入了多跳连接^[14]。在密集块的基础上, 设计了残余密集旁路块 [图 1(c)], 它将密集连接块与旁路残余块相结合^[15]。Li 等人^[16]设计了一个多尺度残差块 (MSRB)[图 1(b)], 它采用不同大小的卷积核来检测不同尺度的特征, 并在不同尺度特征之间应用跳过连接。

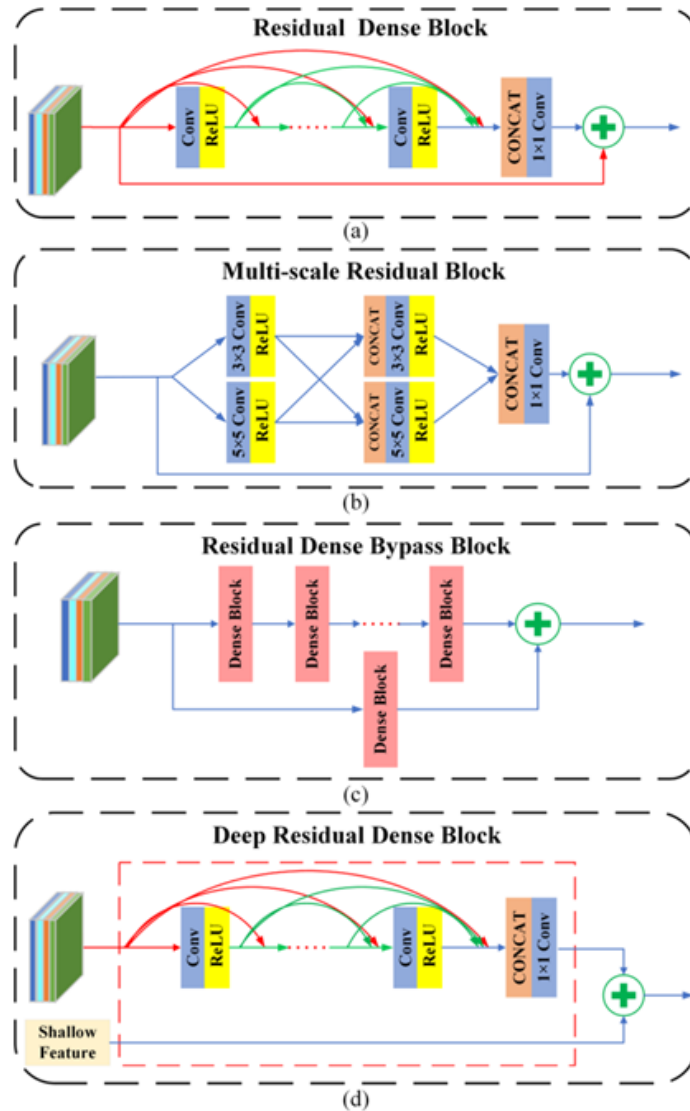


图 1: 几个特征提取块的结构。(a) RDB。(b) MSRB。(c) 剩余密集旁路块。(d) 深度 RDB。□ 表示元素相加的操作。

3 本文方法

3.1 本文方法概述

残差超密集网络（RHDN）是一个带有级联残差超密集块（RHDBs）的卷积神经网络（CNN），允许同一流内的层对和不同流的层对之间的直接连接。它扩展了密集网以解决空谱融合问题，整体结构是一个双分支网络，这使得该网络能够分别捕捉可见光谱范围内和可见光谱范围外的高光谱图像的特征，在网络的每个分支，设计了一个双流特征提取策略来单独处理全色图像和高光谱图像。

RHDN 模型结构如图 2所示：

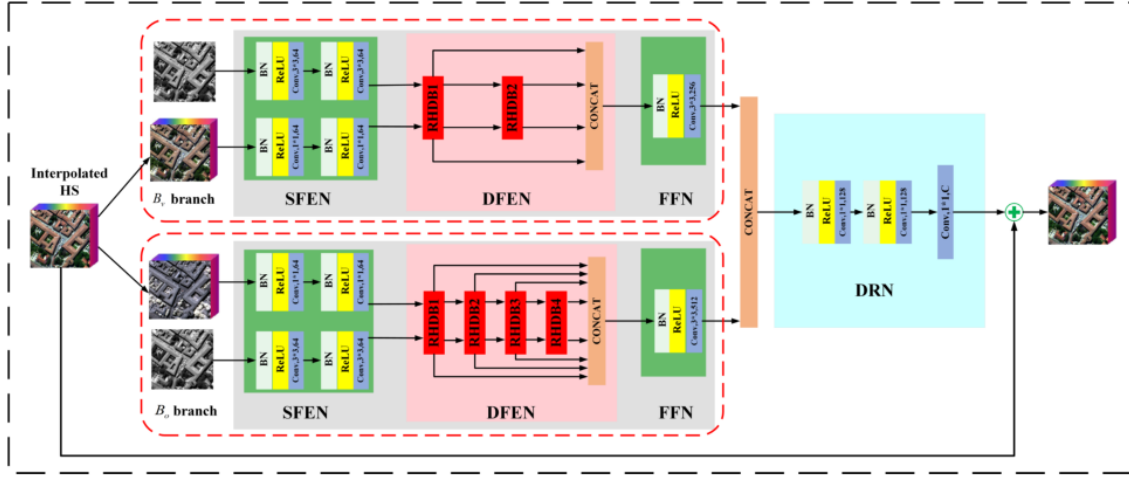


图 2: RHDN 模型结构

3.2 超密集残差模块

一般来说，网络越深，泛锐化的性能就越好。然而，大多数基于 CNN 的深层架构会导致梯度消失的问题。对于 HS 泛锐化任务，现有的方法是直接将 PAN 和 HS 图像级联，然后用特征提取块提取特征并重建 HS 图像，这不利于提取 PAN 图像的空间信息。为了解决上述问题，文章提出了一种用于 HS 泛锐化的超密集残差模块 RHDB，它扩展了 HS 和 PAN 特征提取流内部和中间的低级和高级特征之间的密集连接。RHDB 的结构如图 3所示。为了简单起见，我们只显示一个 RHDB 块。

进一步推动这一思路，提出的 RHDB 将 RDB 的定义扩展到多流空间-光谱融合问题，即充分利用自己流内的分层特征，从不同流中读取特征。换句话说，如图 3所示，我们首先设计一个双流 RDB 结构，分别提取同一流内 HS 和 PAN 图像的层次密集特征，然后在不同流的所有层次之间建立连接。

如图 4（a）所示。我们增加了一个 CA 模块来利用 HS 图像的特征的通道间关系。这是因为不同的通道包含不同的信息，对泛锐化图像的贡献不同。因此，采用 CA 模块来强调更多相关通道，并抑制不太重要的通道。如图 4(b) 所示。与 CA 模块不同，SA 模块关注的是有利于泛锐化中空间细节增强的信息区域。CA 和 SA 模块改善了两个流的所有层次之间的信息和梯度的流动，从而提高了学习表示的有效性。RHDB 以前馈的方式将两个流的所有前层的所有特征输出连接起来。密集的连接发生在两个流的所有层内和层间。与只从自己的流中提取特征的双流块（TSB）相比，RHDB 不仅充分利用了自己流中的分层特征，而且还充分地利用了不同流中的互补性特征。因此，RHDB 通过探索流内和流间各层之间的层次特征，显示出更强大的特征表示。

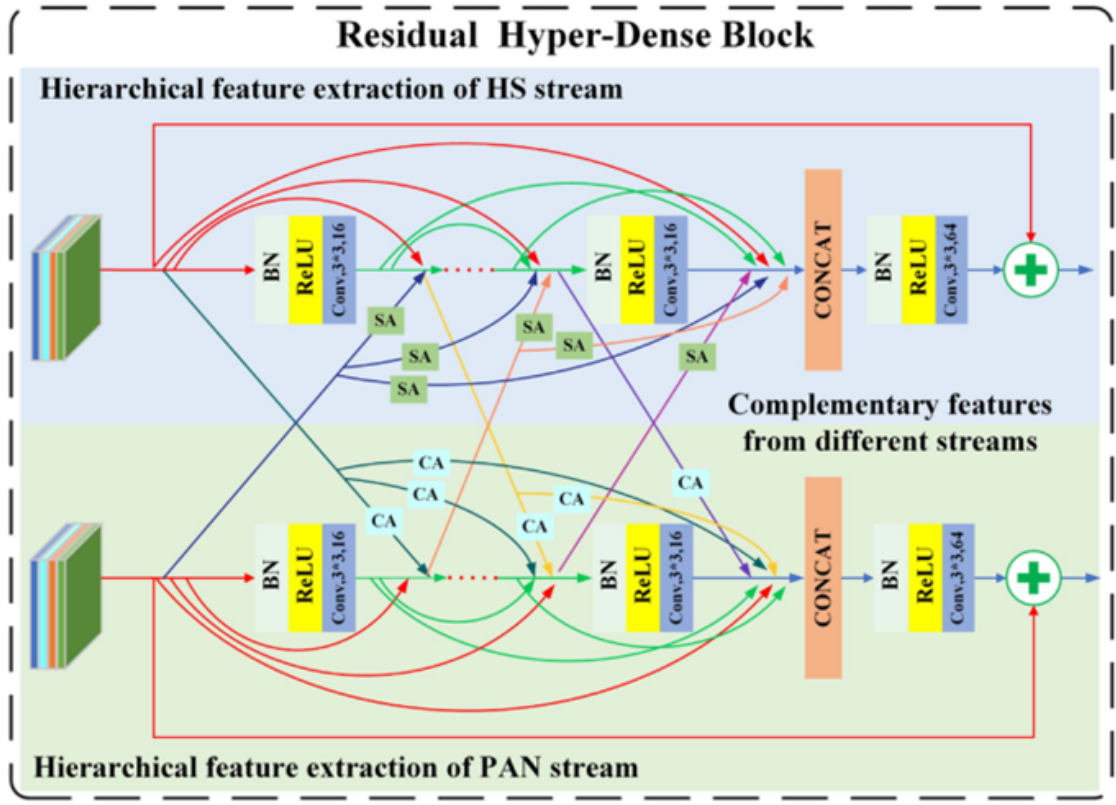


图 3: RHDB 模块结构




图 4: (a) CA 模块的结构。(b) SA 模块的结构。□ 和 □ 分别表示元素相乘和元素相加的操作。

3.3 提出的 RHDN 的网络结构

图 5显示了所提出的 RHDN 方法的结构，它由四个主要步骤组成。SFEN, DFEN, FFN, 和 DRN。

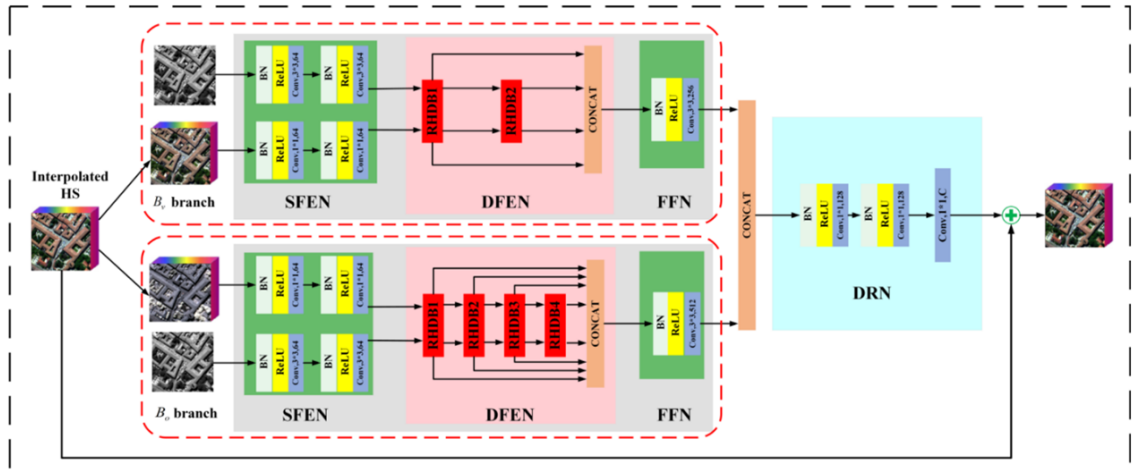


图 5: RHDN 方法结构。Bv 和 Bo 分别表示可见光谱内和外的两个特征提取分支。

由于所需的 HR-HS 图像和 PAN 图像的分辨率与 LR-HS 图像的分辨率不同，LR-HS 图像首先使用双线性插值方法被上采样到与 PAN 图像相同的大小。

3.3.1 浅层特征提取 SFEN

所提出的 RHDN 方法包含一个具有深度结构的双分支网络，可以分别捕获可见光谱范围内和可见光谱范围外的 HS 图像的特征。在每个分支，我们采用双流特征提取子网络来提取 PAN 和 HS 图像的细节。用于提取浅层特征子网络 SFEN 由 N 个卷积块构成，每个卷积块由批处理正常化（BN）层、整流线性单元（ReLU）层和卷积层组成（见图 5）。

HS 图像在一定的光谱范围内被密集地连续采样，因此它们具有较高的光谱分辨率，但空间分辨率较低。在 SFEN 的 HS 特征提取流中，采用两个具有 1×1 卷积核的卷积块来提取 HS 图像的浅层光谱特征。PAN 的 SFEN 流与 HS 的特征提取流保持类似的结构。考虑到相邻的像素，它与 HS SFEN 流的结构有很大不同。在 PAN SFEN 步骤中，两个具有 3×3 卷积核的卷积块被用来充分利用相邻像素的空间信息，使用更大的感受野。

3.3.2 深度特征提取

DFEN 子网络主要由 RHDB 组成（见图 5），它允许同一流内的层对和不同流的层对之间的直接连接。SFEN 子网络的两个流的特征被送入这个后续的 DFEN 子网络。由于 RHDB 完全利用了两个流内部和中间的每个卷积层之间的信息，两个流中每个 RHDB 块的输出都可以被视为局部特征。

3.3.3 密集的前馈网络 FFN

当用一组 RHDB 提取分层特征时，进行密集的 FFN 来融合从前面各层提取的特征。FFN 的结构包含一个卷积块（见图 5）。它通过 CNN 自动学习的权重来融合特征。

3.3.4 细节重构 DRN

Bo 保持着与 Bv 类似的结构。定义一个泛锐化模型的困难在于如何在 PAN 图像没有覆盖的光谱范围内产生良好的性能。因此，关于 Bo 的 DFEN 子网络，它与 Bv 的子网络有很大不同。Bo 的 DFEN 比 Bv 的包含更多的 RHDB。两个子网络所提取的特征沿着光谱维度被串联起来，并被送入下面的 DRN 子网络，在 DRN 中，两个卷积块被堆叠起来以提高表示能力，一个卷积层被用来重建细节图。

3.3.5 损失函数

如图 5 所示，重构出来的图像应尽可能地接近理想的图像。L1 损失函数已被证明在图像重建中是有效的^[17]，也被证明是泛锐化的最佳选择。在本研究中，我们使用 L1 作为损失函数来训练提议的 RHDN 方法。

4 复现细节

4.1 与已有开源代码对比

作者在 GITHUB 上开源了 RHDN 的模型代码和训练代码。在本次复现过程中，首先复现 RHDN 的模型代码和训练代码，与作者公开的代码相比复现的代码删除了一些冗余的参数项，优化了训练模

型的保存策略，增加了训练过程中的验证，增加训练过程的可视化和融合结果的可视化伪彩效果，增加了四个对融合结果的评价指标；其次，按照论文的描述实现了高光谱图像数据集的模拟退化代码有些细节在文中没有描述，导致最后生成的数据和作者制作的数据有出入；下一步，实现 RHDN 的两个变种，TTSN 和 Baseline。TTSN 把 RHDN 中的 RHDB 替换为 TSB，TSB 就是把 RHDB 中双流之间的密集连接（使用注意力的连接）去掉使其变成一个普通的双流 RDB 块，Baseline 是一个单分支网络，和 RHDN 相比，砍去一个网络分支，在网络中使用更多的 RHDB 块来提取特征。最后实现四个对比算法来复现实验，它们分别是 GSA、MTF-GLP、MTF-GLP-HPM、CNMF，对比算法的实现参考了代码 https://github.com/codegaj/py_pansharpening。

4.2 实验环境搭建

复现的方法是基于 Pytorch 框架实现的，并在 Intel(R) Core(TM) i7-6700 CPU@3.40GHz3.41 GHz 上进行训练，训练使用 Adam 优化器更新模型参数，学习率初始化为 0.001，并在每 150 个历时中减少 10 倍。批量大小被设置为 4，优化在第 500 个 epoch 时终止。

4.3 使用说明

将准备好的高光谱图像数据集放入与 src 文件夹同级的 data 文件夹中，每个数据集独占一个文件夹并以数据集名称命名，运行代码第一步在准备运行的 py 文件中设置好数据集路径。运行 datapreprocess.py 处理切分数据集，运行 main.py 训练或测试要先设置训练测试标志（true 训练，false 测试）。运行 contrast_algorithm.py 执行所有对比算法并输出结果。fusion 文件夹保存融合结果的 mat 文件，logs 文件夹保存训练日志文件，results 文件夹保存融合结果的伪彩图片，weights 文件夹保存模型参数。

4.4 创新点

在实验复现过程中发现文章所提出的模型的泛化能力较差，即使在同一个数据集上，用不同的图片模拟退化方法所产生的数据训练出来的模型性能也相差甚远，因此在复现 RHDN 的基础上又实现了 TTSN、Baseline，并且在 RHDN 和 TTSN 上都实现了可见光分支 2RHDB 块不可见光分支 4RHDB 块和可见光分支 4RHDB 块不可见光分支 4RHDB 块两种模型结构，在 Baseline 上实现 8RHDB、10RHDB 两种模型结构。

5 实验结果分析

5.1 实验设置

实验使用 pavia 数据集，从完整图像上裁剪 $960 \times 640 \times 102$ 大小的子图像。最后的评价指标使用光谱角度映射器 Spectral angle mapper(SAM)，用于测量融合图像中原始图像的光谱保真度；交叉相关 Cross correlation(CC)，用于描述泛锐化图像的几何失真，越接近 1 越好；均方根误差 Root-mean-squared error(RMSE) 以及相对无尺寸全局误差 relative dimensionless global error in synthesis(ERGAS)，做全面的质量评估。

5.2 实验结果

复现的论文方法及其变种在 pavia 数据集上的融合结果和对比算法的融合结果在四种评价函数上的表现如表 1 所示

经过上述试验后，发现与论文结果有差异，通过不断调试猜测是模拟退化文中没有给出具体方案，

表 1: 复现方法与传统方法实验结果

算法	模块数	CC	SAM	RMSE	ERGAS
RHDN	2+4	0.9222	10.1432	0.0337	11.024
RHDN	4+4	0.9291	10.0909	0.0310	8.2971
TTSN	2+4	0.9288	9.3435	0.0322	9.2255
TTSN	4+4	0.9307	9.1546	0.0312	8.3951
Baseline	8	0.9341	8.9783	0.0299	8.0002
Baseline	10	0.9339	9.1571	0.0299	7.9335
GSA	-	0.9553	8.0654	0.0152	6.0054
MGP	-	0.9215	8.7093	0.0193	7.1088
MGH	-	0.8958	8.1161	0.0237	8.8368
CNMF	-	0.9578	8.5943	0.0147	5.3291

表 2: 统一数据集不同模拟退化方法实验结果

数据集模拟退化方法	CC	SAM	RMSE	ERGAS
作者	0.9815	3.9576	0.0144	2.7408
我	0.8192	17.0557	0.0521	17.9471

由此造成的差异导致了效果不佳，因此又增加了一个实验，使用作者公布的已经训练好的模型参数分别在作者模拟退化切分的数据和复现的模拟退化切分数据上做测试实验，实验结果如表 2 所示。

5.3 结果分析

通过几组对比实验可以看出来，哪怕在同一个数据集上，不同的模拟退化方法对模型能力的影响也是相当大的，这也反映出方法的泛化能力可能有待商榷，因为手上没有现成的低分辨率高光谱图像也无法对这一结论做更精确的验证。也有一种可能是作者使用的模拟退化方法把数据处理的更为接近真实的低分辨率高光谱图像因此有更好的效果。

6 总结与展望

论文算法 RHDN 以及它的两个变种 TTSN、Baseline 在空谱融合方面确实有一定的效果，但是泛化能力有些欠缺，在换一种数据模拟退化处理方法的情况下表现出来的效果不如某些传统算法，另一方面也有复现的模拟退化处理方法确实不是最合适的问题。后续的研究主要就是对模型的泛化能力以及如何做好数据的模拟退化处理来进行。

除此之外，由于设备和时间的限制有些实验没有做完，在目前的数据上，三种模型的主要模块数增加的话模型表现效果也在变好，后续继续做这方面的实验，找出在已有数据集上最好的模块数量配置；目前所有的实验也只有一个数据集上跑过，后续增加几个公开数据集的实验，确保实验得到可信度。

参考文献

- [1] MOHAMMADZADEH A, TAVAKOLI A, ZOEJ M J V . Road extraction based on fuzzy logic and mathematical morphology from pan-sharpened IKONOS images[J]. Photogram. Rec., 2006, 21(113): 44-60.
- [2] SUN W, SHAO W, PENG J, et al. RMultiscale low-rank spatial features for hyperspectral image classification[J]. IEEE Geosci. Remote Sens. Lett., 2020, 19: 1-5.

- [3] QU J, XU Y ., W. DONG Y . L, et al. Dual-branch difference amplification graph convolutional network for hyperspectral image change detection[J]. IEEE Trans. Geosci. Remote Sens., 2022, 60: 1-12.
- [4] DUAN P, KANG X, LI S, et al. Multichannel pulse-coupled neural network-based hyperspectral image visualization[J]. IEEE Trans. Geosci. Remote Sens., 2020, 58(4): 2444-2456.
- [5] SUN W, K. REN X M, XIAO C, et al. A band divide-and-conquer multispectral and hyperspectral image fusion methodn[J]. IEEE Trans. Geosci. Remote Sens., 2021, 60: 1-13.
- [6] WANG Z, CHEN B, R. LU H Z, et al. FusionNet: An unsupervised convolutional variational network for hyperspectral and multispectral image fusion[J]. IEEE Trans. Image Process., 2020, 29: 7565-7577.
- [7] DONG W, HOU S, XIAO S, et al. Generative dualadversarial network with spectral fidelity and spatial enhancement for hyperspectral pansharpening[J]. IEEE Trans. Neural Netw. Learn. Syst., early access, 2021.
- [8] KWAN C, CHOI J H, CHAN S H, et al. A super-resolution and fusion approach to enhancing hyperspectral images[J]. Remote Sens., 2018, 10(9): 1416.
- [9] LONCAN. L. Hyperspectral pansharpening: A review[J]. IEEE Trans. Geosci. Remote Sens., 2015, 3(3): 27-46.
- [10] YOKOYA N, AIRI T Y, IWASAKI A. Coupled nonnegative matrix factorization unmixing for hyperspectral and multispectral data fusion[J]. IEEE Trans. Geosci. Remote Sens., 2012, 50(2): 528-537.
- [11] ZHENG Y ., LI J, LI Y ., et al. Hyperspectral pansharpening using deep prior and dual attention residual network[J]. IEEE Trans. Geosci. Remote Sens., 2020, 58(11): 8059-8076.
- [12] HE L, ZHU J, LI J, et al. HyperPNN: Hyperspectral pansharpening via spectrally predictive convolutional neural networks[J]. IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens., 2019, 12(8): 3092-3100.
- [13] ZHANG Y ., TIAN Y ., KONG Y ., et al. Residual dense network for image super-resolution[J]. in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2018: 2472-2481.
- [14] WANG W, JIANG Y ., LUO Y ., et al. An advanced deep residual dense network (DRDN) approach for image superresolution[J]. Int. J. Comput. Intell. Syst., 2019, 12(2): 1592-1601.
- [15] XU J, CHAE Y ., STENGER B, et al. Dense byNet: Residual dense network for image super resolution [J]. in Proc. 25th IEEE Int. Conf. Image Process. (ICIP), 2018: 71-75.
- [16] LI J, FANG F, MEI K, et al. Multi-scale residual network for image super-resolution[J]. in Proc. Eur. Conf. Comput. Vis. (ECCV), 2018: 527-542.
- [17] ZHAO H, GALLO O, FROSIO I, et al. Loss functions for image restoration with neural networks[J]. IEEE Trans. Comput. Imag., 2017, 3(1): 47-57.